

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN



BÁO CÁO MÔN HỌC
HỌC SÂU CHO KHOA HỌC DỮ LIỆU

GVHD: Hà Minh Tuấn
Môn học: Học sâu cho khoa học dữ liệu
Mã học phần: MTH10622
Đề tài: Phân loại đa nhãn cảm xúc văn bản
(Multi-label Text Emotion Classification)

SINH VIÊN THỰC HIỆN:

Nguyễn Thị Yến Nhiên	23280076
Hoàng Ngô Hà Phương	23280079
Trần Nguyễn Anh Thi	23280085

Mục lục

1	Giới thiệu tổng quan	2
1.1	Đặt vấn đề	2
1.1.1	Sự phức tạp của Multi-label so với Multi-class	2
1.2	Mục tiêu	2
1.3	Giới hạn tài nguyên	3
2	Mô tả bộ dữ liệu và Tiền xử lý	4
2.1	Tổng quan về tập dữ liệu GoEmotions 28 lớp	4
2.2	Phân tích khám phá dữ liệu (EDA)	4
2.3	Xây dựng Pipeline và Xử lý mất cân bằng nhãn (pos_weight)	4
3	Kiến trúc hệ thống và Phương pháp nghiên cứu	6
3.1	Mô hình tự thiết kế Bi-LSTM Classifier	6
3.2	Mô hình Transformer DistilBERT Advanced	6
3.3	Chiến lược tìm kiếm siêu tham số và Tối ưu hóa hội tụ	6
4	Phân tích kết quả thực nghiệm	7
4.1	Thiết lập môi trường và Công cụ giám sát Weights & Biases	7
4.2	Kết quả mô hình nền tảng Bi-LSTM (Trước và sau khi bật weights)	7
4.3	Kết quả tinh chỉnh DistilBERT	7
4.4	Đánh giá so sánh hiệu năng qua các hệ số Macro/Micro F1	7
4.5	Phân tích lỗi hệ thống (Error Analysis)	7
5	Kết luận	8

Chương 1

Giới thiệu tổng quan

1.1 Đặt vấn đề

Sự phát triển của mạng xã hội đã tạo ra một lượng lớn dữ liệu văn bản chứa đựng cảm xúc và ý kiến của con người.

Việc phân loại cảm xúc trong văn bản trở thành một nhiệm vụ quan trọng trong lĩnh vực xử lý ngôn ngữ tự nhiên (NLP) với nhiều ứng dụng thực tế như phân tích thị trường, chăm sóc khách hàng, và nghiên cứu xã hội học.

Tuy nhiên, một câu văn không phải lúc nào cũng chỉ thể hiện một cảm xúc duy nhất mà có thể đồng thời chứa nhiều trạng thái cảm xúc khác nhau.

Bộ dữ liệu GoEmotions do Google nghiên cứu sở hữu hệ thống phân loại tinh tế lên đến 28 lớp cảm xúc khác nhau đan xen.

Điều này đặt ra một bài toán Phân loại đa nhãn (Multi-label Classification) đầy thách thức: ranh giới giữa các cảm xúc rất mong manh (ví dụ giữa tức giận và khó chịu), đồng thời phân phối dữ liệu bị mất cân bằng nghiêm trọng giữa các nhãn phổ biến và nhãn hiếm.

1.1.1 Sự phức tạp của Multi-label so với Multi-class

So với bài toán phân loại đa lớp (Multi-class), bài toán phân loại đa nhãn (Multi-label) có độ phức tạp cao hơn ở các khía cạnh sau:

- **Không gian nhãn:** Trong bài toán Multi-class, mỗi văn bản chỉ thuộc duy nhất một lớp. Ngược lại, ở bài toán Multi-label, một văn bản có thể đồng thời thuộc nhiều lớp cảm xúc khác nhau. Ví dụ, một câu có thể vừa thể hiện cảm xúc vui vẻ vừa ngưỡng mộ.
- **Độ phức tạp của dự đoán:** Với bài toán Multi-class, mô hình chỉ cần chọn một nhãn duy nhất cho mỗi văn bản. Trong khi đó, bài toán Multi-label phải xem xét nhiều tổ hợp nhãn khác nhau, làm tăng đáng kể độ phức tạp của quá trình học và dự đoán.
- **Đánh giá mô hình:** Accuracy không còn là thước đo phù hợp cho bài toán Multi-label vì nó chỉ đánh giá đúng khi tất cả các nhãn được dự đoán chính xác. Thay vào đó, các chỉ số như Macro F1 và Micro F1 được sử dụng để đánh giá hiệu suất của mô hình trên từng nhãn và toàn bộ tập dữ liệu.

1.2 Mục tiêu

Dự án tập trung vào việc xây dựng một quy trình (pipeline) hoàn chỉnh từ xử lý dữ liệu ngôn ngữ thô đến triển khai hệ thống phân loại đa nhãn cảm xúc văn bản. Các mục tiêu cụ thể bao gồm:

- Xây dựng quy trình tiền xử lý dữ liệu văn bản và chuẩn bị dữ liệu cho bài toán phân loại cảm xúc đa nhãn.

- Xây dựng và huấn luyện mô hình Bi-LSTM làm mô hình cơ sở (Baseline) cho bài toán.
- Áp dụng các kỹ thuật xử lý mất cân bằng dữ liệu nhằm cải thiện khả năng nhận diện các nhãn cảm xúc hiếm.
- Tinh chỉnh mô hình Transformer DistilBERT để đạt hiệu suất cao hơn trên tập dữ liệu GoEmotions.
- Sử dụng Weights & Biases (W&B) để tự động theo dõi quá trình huấn luyện, đánh giá và so sánh hiệu năng của các mô hình.

1.3 Giới hạn tài nguyên

Hệ thống huấn luyện và thực nghiệm của đề tài được thực hiện trên môi trường Google Colab miễn phí với các hạn chế về tài nguyên tính toán như GPU, bộ nhớ RAM và thời gian huấn luyện. Do đó, kích thước mô hình, số lượng epoch và phạm vi thực nghiệm được điều chỉnh phù hợp nhằm đảm bảo khả năng triển khai và đánh giá.

- **GPU:** Các thực nghiệm được thực hiện trên GPU Nvidia T4 (16GB VRAM) do Google Colab cung cấp.
- **RAM:** Bộ nhớ hệ thống khoảng 12 GB, giới hạn khả năng huấn luyện các mô hình có kích thước lớn.
- **Thời gian huấn luyện:** Phiên làm việc của Google Colab miễn phí có thời lượng sử dụng giới hạn, ảnh hưởng đến việc thực hiện các thực nghiệm kéo dài.

Chương 2

Mô tả bộ dữ liệu và Tiền xử lý

2.1 Tổng quan về tập dữ liệu GoEmotions 28 lớp

GoEmotions là bộ dữ liệu văn bản tiếng Anh quy mô lớn được thu thập từ các bình luận trên nền tảng Reddit.

- **Đặc trưng cốt lõi:** Cấu trúc đa nhãn (Multi-label) với 28 phân lớp, bao gồm 27 sắc thái cảm xúc và 1 nhãn trung tính (Neutral).
- **Định dạng dữ liệu:** Dữ liệu gốc được cung cấp dưới định dạng Multi-hot Encoding (ma trận chứa các giá trị 0 và 1), cho phép biểu diễn thực tế rằng một câu văn có thể mang nhiều cảm xúc đan xen cùng lúc.

2.2 Phân tích khám phá dữ liệu (EDA)

Quá trình kiểm tra tình trạng dữ liệu (Data Health Check) cho thấy hai đặc tính quan trọng:

- **Độ sạch cơ bản:** Dữ liệu không chứa giá trị khuyết thiếu (NaNs). Các dòng văn bản trùng lặp xuất hiện với tần suất cao nhưng mang tính hợp lệ do đặc thù nhiều người cùng đánh giá (Multi-rater annotations) trên một mẫu câu.
- **Phân phối nhãn:** Tập dữ liệu tồn tại sự mất cân bằng (Class Imbalance). Phân tích chỉ ra các nhãn đa số như Neutral hay Admiration chiếm tỷ trọng áp đảo, trong khi các nhãn thiểu số như Grief hay Pride xuất hiện rất thưa thớt.
- **Đa nhãn phổ biến:** Một số mẫu câu có xu hướng mang nhiều nhãn cảm xúc cùng lúc, đặc biệt là các cặp cảm xúc thường đi kèm như Anger và Disgust, hoặc Joy và Love.

2.3 Xây dựng Pipeline và Xử lý mất cân bằng nhãn (pos_weight)

Để chuẩn bị dữ liệu đầu vào tối ưu cho mô hình Deep Learning, luồng xử lý (Data Pipeline) ba bước đã được thiết kế và thực thi:

- **Bước 1 - Gộp nhãn và xử lý xung đột logic:** Áp dụng hàm `.max()` để hợp nhất các đánh giá đa người dùng thành một dòng duy nhất. Đặc biệt, hệ thống xử lý triệt để "Nghịch lý Neutral" bằng cách thiết lập luật ưu tiên: Nếu một câu văn chứa ít nhất một nhãn cảm xúc dương tính, nhãn Neutral của câu đó bắt buộc phải bị ép về 0 để đảm bảo tính nhất quán logic.
- **Bước 2 - Tiền xử lý tối thiểu (Minimal Preprocessing):** Thay vì dọn dẹp cực đoan, dự án áp dụng chiến lược giữ lại tối đa ngữ cảnh cảm xúc. Quy trình bao gồm việc loại bỏ nhiễu kỹ

thuật số (URLs, HTML, Tags ẩn danh). Các tín hiệu cảm xúc mạnh như biểu tượng (Emoji) được dịch tự động thành văn bản tiếng Anh thông qua thư viện emot, kết hợp bung các từ viết tắt (contractions). Bộ lọc cũng chủ đích giữ lại các câu cảm thán siêu ngắn (1-2 từ) nhằm cung cấp đủ tín hiệu (signal) cho cơ chế Attention của mô hình.

- **Bước 3 - Giải quyết mất cân bằng & Phân chia dữ liệu:** Để khắc phục tình trạng phân phối nhãn lệch, một tensor trọng số lớp *pos_weights* được tính toán dựa trên công thức nghịch đảo: Số mẫu âm tính chia cho số mẫu dương tính. Trọng số này sẽ được tích hợp trực tiếp vào hàm Loss của PyTorch. Cuối cùng, dữ liệu sạch được phân tách ngẫu nhiên thành ba tập Train/Validation/Test theo tỷ lệ 80/10/10 trước khi xuất ra định dạng CSV chuẩn utf8sig.

Chương 3

Kiến trúc hệ thống và Phương pháp nghiên cứu

3.1 Mô hình tự thiết kế Bi-LSTM Classifier

3.2 Mô hình Transformer DistilBERT Advanced

3.3 Chiến lược tìm kiếm siêu tham số và Tối ưu hóa hội tụ

Chương 4

Phân tích kết quả thực nghiệm

- 4.1 Thiết lập môi trường và Công cụ giám sát Weights & Biases
- 4.2 Kết quả mô hình nền tảng Bi-LSTM (Trước và sau khi bật weights)
- 4.3 Kết quả tinh chỉnh DistilBERT
- 4.4 Đánh giá so sánh hiệu năng qua các hệ số Macro/Micro F1
- 4.5 Phân tích lỗi hệ thống (Error Analysis)

Chương 5

Kết luận